

Ingeniería de soluciones con AI

Semestre 2026-1

Docente:
Francisco Macaya

Noticias: Prompt injection es todavía una amenaza.

Brands That Matter Extended Deadline Friday, 5/29

LOGIN

FASTCOMPANY

SUBSCRIBE

NEWS TECH DESIGN LEADERSHIP WORK LIFE MOST INNOVATIVE COMPANIES GAMES PODCASTS VIDEO EVENTS | CUSTOM STUDIO

There's no rogue McDonald's AI bot, but 'prompt injection' is still a risk for companies

People hacking branded AI bots can result in significant reputational, financial, and legal consequences.

SHARE ADD ON GOOGLE



[Source Images: McDonald's and Freepik]

BY JESUS DIAZ

ADVERTISEMENT

Considering a career at Citi?



Global benefits

Apply Now

citi

FEATURED VIDEO


Nota: <https://www.fastcompany.com/91532091/mcdonalds-ai-bot-didnt-go-rogue>

¿Por qué es relevante la seguridad?



La **seguridad** es el piso mínimo de un diseño, no es una característica

Ataques comunes de AI.



Deep Seek: ¿Cómo inicialmente fueron tan baratos?

OpenAI says China's DeepSeek trained its AI by distilling US models, memo shows


By Deepa Seetharaman and Fabiola Arámburo

February 12, 2026 10:16 PM GMT · Updated February 13, 2026



China's DeepSeek shook markets early last year with a set of AI models that rivaled some of the best offerings from the U.S.

Destilación (Distillation): Aprende de los mayores.



Mucho más barato que entrenar un modelo con millones de parámetros. Deep Seek crearon miles de cuentas de OpenAI para entrenar su propio modelo.

Guardrails: Protege tu sistema ante filtraciones.

Inputs Guardrails

Las dos principales fugas que evitan son:

1. filtrar información privada a API externas.
2. ejecutar mensajes maliciosos que comprometen su sistema

¿Cómo puede pasar?:

1. Un empleado copia información confidencial de la empresa o información privada de un usuario en un mensaje y la envía a una API de terceros.¹
2. Un desarrollador de aplicaciones introduce políticas y datos internos de la empresa en el mensaje del sistema de la aplicación.
3. Una herramienta recupera información privada de una base de datos interna y la agrega al contexto.




Figure 10-3. An example of masking and unmasking PII information using a reverse PII map to avoid sending it to external APIs.

Guardrails: Protege tu sistema ante filtraciones.

Output Guardrails

Sus funciones son:

1. Detectar fallos de salida.
2. Especificar la política para gestionar los diferentes modos de fallo.

- Quality
 - Malformatted responses that don't follow the expected output format. For example, the application expects JSON, and the model generates invalid JSON.
 - Factually inconsistent responses hallucinated by the model.
 - Generally bad responses. For example, you ask the model to write an essay, and that essay is just bad.
- Security
 - Toxic responses that contain racist content, sexual content, or illegal activities.
 - Responses that contain private and sensitive information.
 - Responses that trigger remote tool and code execution.
 - Brand-risk responses that mischaracterize your company or your competitors.

¿Cómo implementarlo?




Figure 10-4. Application architecture with the addition of input and output guardrails.

Sistema protegido, con **input y output guardrails** para resolver cualquier problema de filtraciones y seguridad.

Éticas y Seguridad: La AI es una herramienta, no el fin.

