

# *Ingeniería de soluciones con AI*

*Semestre 2026-1*

***Docente:***  
*Francisco Macaya*

# Noticias: Magnifica Humanitas, reacción del Papa sobre la AI.

ARTICLES OF FAITH

CULTURE AND CIVILISATIONS

LEARNING AND LIBERTY

Friday May 29, 2026

## 'Magnifica Humanitas': AI and the Pope

by [BENEDIKT KOEHLER](#)

SHARE:     

Member ratings

Well argued: **87%**   Interesting points: **93%**   Agree with arguments: **75%**

4 ratings - [view all](#)



Pope Leo XIV

### Latest articles

The Prado

by [JEFFREY MEYERS](#) 31 MAY 2026

Popski's Private Army: a very little platoon

by [PATRICK HEREN](#) 30 MAY 2026

How to innovate in business and embrace change

by [CASS BUSINESS SCHOOL](#) **★ SPONSORED**

Movebound: the art of Zugzwang

by [RAYMOND KEENE](#) 30 MAY 2026

'Magnifica Humanitas': AI and the Pope

by [BENEDIKT KOEHLER](#) 29 MAY 2026

**Nota:** <https://www.thearticle.com/magnifica-humanitas-ai-and-the-pope>

## REPASO

*¿Cuál es la diferencia entre la inteligencia artificial que uso en visual studio code o el chatGPT y el código de mi agente de la evaluación 2?*


## REPASO

*¿Qué es un sistema multi-agente?*

*[https://github.com/Foco22/INGENIERIA-DE-SOLUCIONES-CON-INTELIGENCIA-ARTIFICIAL\\_002D\\_OLS/tree/main/Experiencia%20de%20Aprendizaje%202%20-%20Desarrollo%20de%20Agente%20Inteligentes%20con%20AI/Clase%202.3](https://github.com/Foco22/INGENIERIA-DE-SOLUCIONES-CON-INTELIGENCIA-ARTIFICIAL_002D_OLS/tree/main/Experiencia%20de%20Aprendizaje%202%20-%20Desarrollo%20de%20Agente%20Inteligentes%20con%20AI/Clase%202.3)*

# *¿Cuál es la diferencia entre AI y ML?*

## REPASO




Artificial intelligence (AI) is technology that enables computers and machines to simulate human learning, comprehension, problem solving, decision making, creativity and autonomy

<https://www.ibm.com/think/topics/artificial-intelligence>


# ¿Cuál arquitectura es más escalable?

## Plan A



**REPASO**

## Plan B



El agente supervisor decide a qué nodo dirigirse en función de las palabras proporcionadas por el usuario. Por ejemplo, si el usuario utiliza términos como "comprar", "compras", "comprarías" o similares, el supervisor selecciona el Agente A.

El agente supervisor invoca a un LLM, que en base a un prompt de sistema, y una instrucción clara, decide a que agente debe llamar en cada momento.

## *¿Cómo se escribe un endpoint (API) correctamente?*

### REST best practices (1/2)

- ✔ Use forward slash (/) to indicate hierarchical relationships
  - › `http://stelios.io/api`
  - › `http://stelios.io/api/users`
  - › `http://stelios.io/api/users/{id}`
- ✔ Do not use trailing forward slash (/) in URIs
  - › `http://stelios.io/api/users/`      */\*Do not use this\*/*
  - › `http://stelios.io/api/users`      */\*This is better\*/*
- ✔ Use hyphens (-) to improve the readability of URIs, do not use underscores (\_) *(\_)*
  - › `http://stelios.io/api/users/mini_film/{id}`      */\*Do not use this \*/*
  - › `http://stelios.io/api/users/mini-film/{id}`      */\*This is better\*/*

### REST best practices (2/2)

- ✔ Use lowercase letters in URIs
- ✔ Do not use file extensions
  - › `http://stelios.io/api/users/user-data.json`      */\* Do not use this \*/*
- ✔ Never use CRUD function names in URIs
  - › `http://stelios.io/api/users/get-users`      */\* Do not use this \*/*
  - › `http://stelios.io/api/users`      */\* This is better \*/*

## *Escalabilidad de un sistema: Mas maquinas o mas potencia.*

### Horizontal vs Vertical scaling

- Horizontal: Add more instances on a cluster
- Vertical: Increase the size of the virtualized resource (e.g., CPU, RAM, etc.)



What is the problem with Vertical?

- Servers have limits

What is the problem with Horizontal?

- It's a distributed system

*Ejemplos: Un start-up, con pocos usuarios, suele ser monolito.*

## What are examples of vertical/horizontal scaling systems?

### Vertical



Monolithic Web Applications

Relational Databases (e.g., MySQL)

Virtualization and Virtual Machines

Legacy Enterprise Applications

### Horizontal

Web Applications with Load Balancing

Microservices Architectures


NoSQL Databases (e.g., MongoDB)

Containers and Kubernetes



*¿Cuánto moverse?: Suele ser una decisión económica.*


## Vertical vs Horizontal cost



***Kubernetes:** La solución escalable que soluciona cualquier tipo de problema de conexión entre VMs.*

## The Kubernetes system

- ✓ The master node(s) host the control plane aspects of the cluster
  - Kubernetes API server
  - Scheduler
  - Controller
  - Etcd
- ✓ Workers are the workforce, they run our containers!



*Este ramo no es sobre Kubernetes. No es complicado configurarlo, ya que hoy en día, con GCP, es bastante fácil montar estos servicios, el problema es el costos, y que aplica solo a empresas que tienen un flujo de información alta, no a pequeñas empresas.*

## *Optimización por inferencia de servicio: GPU más eficiente.*




Figure 9-15. Dynamic batching keeps the latency manageable but might be less compute-efficient.

*Requests esperan como en un Bus en **Static batching**, y en **Dynamic batching**, esperan como en un bus, o hasta un cierto tiempo.*

# Prompt caching: No te repitas a ti mismo.




Figure 9-17. With a prompt cache, overlapping segments in different prompts can be cached and reused.

Table 9-3. Cost and latency reduced by prompt caching. Information from Anthropic (2024).

| Use case                                                          | Latency w/o caching (time to first token) | Latency with caching (time to first token) | Cost reduction |
|-------------------------------------------------------------------|-------------------------------------------|--------------------------------------------|----------------|
| Chat with a book (100,000-token cached prompt)                    | 11.5 s                                    | 2.4 s (–79%)                               | –90%           |
| Many-shot prompting (10,000-token prompt)                         | 1.6 s                                     | 1.1 s (–31%)                               | –86%           |
| Multi-turn conversation (10-turn convo with a long system prompt) | ~10 s                                     | ~2.5 s (–75%)                              | –53%           |

*Prompt caching esta disponible por los proveedores de APIs de LLMs, y es una buena forma de optimizar costos.*

# *Oxford Tech Week: Agentes, lot y personas.*

