

Ingeniería de soluciones con AI

Semestre 2026-1

Docente:
Francisco Macaya

Noticias: Magnifica Humanitas, reacción del Papa sobre la AI.

ARTICLES OF FAITH

CULTURE AND CIVILISATIONS

LEARNING AND LIBERTY

Friday May 29, 2026

'Magnifica Humanitas': AI and the Pope

by [BENEDIKT KOEHLER](#)

SHARE:     

Member ratings

Well argued: **87%** Interesting points: **93%** Agree with arguments: **75%**

4 ratings - [view all](#)



Pope Leo XIV

Latest articles

The Prado

by [JEFFREY MEYERS](#) 31 MAY 2026

Popski's Private Army: a very little platoon

by [PATRICK HEREN](#) 30 MAY 2026

How to innovate in business and embrace change

by [CASS BUSINESS SCHOOL](#) **★ SPONSORED**

Movebound: the art of Zugzwang

by [RAYMOND KEENE](#) 30 MAY 2026

'Magnifica Humanitas': AI and the Pope

by [BENEDIKT KOEHLER](#) 29 MAY 2026

Nota: <https://www.thearticle.com/magnifica-humanitas-ai-and-the-pope>

REPASO

¿Cuál es la diferencia entre la inteligencia artificial que uso en visual studio code o el chatGPT y el código de mi agente de la evaluación 2?


REPASO

¿Qué es un sistema multi-agente?

https://github.com/Foco22/INGENIERIA-DE-SOLUCIONES-CON-INTELIGENCIA-ARTIFICIAL_002D_OLS/tree/main/Experiencia%20de%20Aprendizaje%202%20-%20Desarrollo%20de%20Agente%20Inteligentes%20con%20AI/Clase%202.3

¿Cuál es la diferencia entre AI y ML?

REPASO




Artificial intelligence (AI) is technology that enables computers and machines to simulate human learning, comprehension, problem solving, decision making, creativity and autonomy

<https://www.ibm.com/think/topics/artificial-intelligence>


¿Cuál arquitectura es más escalable?

Plan A



REPASO

Plan B



El agente supervisor decide a qué nodo dirigirse en función de las palabras proporcionadas por el usuario. Por ejemplo, si el usuario utiliza términos como "comprar", "compras", "comprarías" o similares, el supervisor selecciona el Agente A.

El agente supervisor invoca a un LLM, que en base a un prompt de sistema, y una instrucción clara, decide a que agente debe llamar en cada momento.

¿Cómo se escribe un endpoint (API) correctamente?

REST best practices (1/2)

- ✔ Use forward slash (/) to indicate hierarchical relationships
 - `http://stelios.io/api`
 - `http://stelios.io/api/users`
 - `http://stelios.io/api/users/{id}`
- ✔ Do not use trailing forward slash (/) in URIs
 - `http://stelios.io/api/users/` */*Do not use this*/*
 - `http://stelios.io/api/users` */*This is better*/*
- ✔ Use hyphens (-) to improve the readability of URIs, do not use underscores (_) */*Do not use this */*
 - `http://stelios.io/api/users/mini_film/{id}` */*Do not use this */*
 - `http://stelios.io/api/users/mini-film/{id}` */*This is better*/*

REST best practices (2/2)

- ✔ Use lowercase letters in URIs
- ✔ Do not use file extensions
 - `http://stelios.io/api/users/user-data.json` */* Do not use this */*
- ✔ Never use CRUD function names in URIs
 - `http://stelios.io/api/users/get-users` */* Do not use this */*
 - `http://stelios.io/api/users` */* This is better */*

Escalabilidad de un sistema: Mas maquinas o mas potencia.

Horizontal vs Vertical scaling

- Horizontal: Add more instances on a cluster
- Vertical: Increase the size of the virtualized resource (e.g., CPU, RAM, etc.)



What is the problem with Vertical?

- Servers have limits

What is the problem with Horizontal?

- It's a distributed system

Ejemplos: Un start-up, con pocos usuarios, suele ser monolito.

What are examples of vertical/horizontal scaling systems?

Vertical



Monolithic Web Applications

Relational Databases (e.g., MySQL)

Virtualization and Virtual Machines

Legacy Enterprise Applications

Horizontal

Web Applications with Load Balancing

Microservices Architectures


NoSQL Databases (e.g., MongoDB)

Containers and Kubernetes



¿Cuánto moverse?: Suele ser una decisión económica.


Vertical vs Horizontal cost



Kubernetes: La solución escalable que soluciona cualquier tipo de problema de conexión entre VMs.


The Kubernetes system

- ✓ The master node(s) host the control plane aspects of the cluster
 - Kubernetes API server
 - Scheduler
 - Controller
 - Etcd
- ✓ Workers are the workforce, they run our containers!



Este ramo no es sobre Kubernetes. No es complicado configurarlo, ya que hoy en día, con GCP, es bastante fácil montar estos servicios, el problema es el costos, y que aplica solo a empresas que tienen un flujo de información alta, no a pequeñas empresas.

Optimización por modelamiento: Hazlo más pequeño.



Nota: <https://www.linkedin.com/pulse/fine-tuning-quantization-distillation-three-very-ways-alvin-kabwama-i47zc/>.

Optimización por inferencia de servicio: GPU más eficiente.




Figure 9-15. Dynamic batching keeps the latency manageable but might be less compute-efficient.

*Requests esperan como en un Bus en **Static batching**, y en **Dynamic batching**, esperan como en un bus, o hasta un cierto tiempo.*

Prompt caching: No te repitas a ti mismo.




Figure 9-17. With a prompt cache, overlapping segments in different prompts can be cached and reused.

Table 9-3. Cost and latency reduced by prompt caching. Information from Anthropic (2024).

Use case	Latency w/o caching (time to first token)	Latency with caching (time to first token)	Cost reduction
Chat with a book (100,000-token cached prompt)	11.5 s	2.4 s (–79%)	–90%
Many-shot prompting (10,000-token prompt)	1.6 s	1.1 s (–31%)	–86%
Multi-turn conversation (10-turn convo with a long system prompt)	~10 s	~2.5 s (–75%)	–53%

Prompt caching esta disponible por los proveedores de APIs de LLMs, y es una buena forma de optimizar costos.

Oxford Tech Week: Agentes, lot y personas.

